

---

# Perbandingan Model dengan Transfer Learning yang Dikombinasikan dengan Algoritma CNN dan RCNN pada Dataset Gambar Diabetes Retina

Inayah Ayu Deswita<sup>1</sup>, Marisah Lofiana<sup>2</sup>, Muhamad Fazar Rizky Ardianto<sup>3</sup>

<sup>1</sup>Department of Informatics, UIN Sunan Gunung Djati Bandung

<sup>2</sup>Department of Informatics, UIN Sunan Gunung Djati Bandung

<sup>3</sup>Department of Informatics, UIN Sunan Gunung Djati Bandung

---

## Article Info

### Article history:

### Keywords:

Convolutional Neural Network (CNN)  
DenseNet  
Deep Learning  
EfficientNet  
Region-based Convolutional Neural Network (RCNN)  
ResNet  
Retinopati Diabetik  
Transfer Learning

---

## ABSTRACT (10 PT)

Retinopati Diabetik (RD) merupakan komplikasi serius dari diabetes yang menjadi penyebab utama kebutaan yang dapat dicegah secara global. Deteksi dini RD sangat krusial, namun diagnosis manual oleh oftalmologis seringkali memakan waktu, subjektif, dan memerlukan keahlian tinggi. Penelitian ini mengusulkan dan membandingkan kinerja model deep learning berbasis *transfer learning* menggunakan arsitektur *Convolutional Neural Network* (CNN) dan *Region-based Convolutional Neural Network* (RCNN) untuk deteksi RD pada citra fundus retina. Tiga arsitektur model *pre-trained* EfficientNetB0, ResNet50, dan DenseNet121 dievaluasi secara komprehensif. Metodologi melibatkan pra-pemrosesan citra ekstensif, augmentasi data untuk mengatasi keterbatasan dataset, dan penanganan ketidakseimbangan kelas. Model dilatih menggunakan *optimizer* Adam dengan fungsi rugi *Categorical Cross-Entropy*, dan kinerjanya diukur berdasarkan Akurasi, Presisi, Recall, dan F1-score pada set pengujian independen. Hasil menunjukkan bahwa DenseNet121 mencapai akurasi tertinggi sebesar 97%, dengan presisi makro 0.98, recall makro 0.97, dan F1-score makro 0.97. EfficientNetB0 dan ResNet50 juga menunjukkan performa yang kompetitif dengan akurasi 94% dan 94% masing-masing. Secara keseluruhan, DenseNet121 menunjukkan kinerja superior dalam klasifikasi RD biner. Penelitian ini menegaskan potensi *transfer learning* dalam mengembangkan sistem skrining RD otomatis yang akurat dan efisien, memberikan wawasan berharga untuk implementasi klinis yang lebih cepat dan efektif.

This is an open access article under the [CC BY-SA](#) license.



---

## Corresponding Author:

Muhamad Fazar Rizky Ardianto  
Jurusan Teknik Informatika, UIN Sunan Gunung Djati Bandung  
Email: Fazarrizkiy007@gmail.com

---

---

## 1. PENDAHULUAN

Retinopati Diabetik (RD) adalah komplikasi mikrovaskular diabetes yang memengaruhi retina mata, menjadikannya penyebab utama kebutaan yang dapat dicegah pada populasi usia produktif secara global [1]. Prevalensi diabetes mellitus terus meningkat secara dramatis di seluruh dunia, dengan proyeksi mencapai 700 juta orang dewasa pada tahun 2045 [2]. Seiring dengan peningkatan ini, beban penyakit RD juga turut meningkat, menuntut strategi deteksi dini dan manajemen yang efektif untuk mencegah progresivitas dan meminimalkan risiko kehilangan penglihatan permanen. Diperkirakan bahwa sekitar sepertiga dari individu dengan diabetes akan mengembangkan beberapa tingkat RD, dan sekitar 10% akan mengalami bentuk yang mengancam penglihatan [3]. Oleh karena itu, skrining rutin sangat krusial, namun diagnosis RD secara tradisional mengandalkan pemeriksaan fundus okuli manual oleh oftalmologis. Proses ini tidak hanya memakan waktu tetapi juga memerlukan keahlian khusus dan pengalaman yang signifikan, serta rentan terhadap variabilitas antar pengamat dan kelelahan, terutama dalam skala populasi besar [4]. Tantangan ini semakin diperparah di daerah dengan keterbatasan sumber daya medis dan jumlah spesialis yang tidak memadai, yang menggarisbawahi kebutuhan mendesak akan alat bantu diagnostik yang efisien, akurat, dan terjangkau.

Dalam dekade terakhir, bidang pembelajaran mendalam (deep learning) telah merevolusi berbagai aplikasi dalam analisis citra, termasuk dalam domain medis. Convolutional Neural Networks (CNN) telah membuktikan kemampuannya yang superior dalam mengekstraksi fitur hirarkis yang kompleks dari gambar, memungkinkan klasifikasi, segmentasi, dan deteksi objek yang presisi [5]. Kemampuan CNN untuk mempelajari representasi data secara otomatis dari citra mentah menjadikannya sangat cocok untuk tugas-tugas seperti analisis citra fundus. Namun, pengembangan model deep learning dari awal seringkali memerlukan dataset yang sangat besar dan sumber daya komputasi yang intensif untuk mencapai kinerja optimal. Untuk mengatasi keterbatasan data berlabel yang sering terjadi di domain medis, transfer learning muncul sebagai paradigma yang powerful. Pendekatan ini memanfaatkan model-model CNN yang telah dilatih sebelumnya (pre-trained models) pada dataset skala besar dan beragam seperti ImageNet (misalnya, EfficientNet, ResNet, DenseNet) [6]. Dengan mengadaptasi bobot dan arsitektur model ini untuk tugas-tugas spesifik, seperti deteksi RD, transfer learning memungkinkan pemanfaatan pengetahuan yang telah diperoleh dari domain yang luas ke domain yang lebih spesifik, sehingga secara signifikan mengurangi kebutuhan akan data berlabel yang sangat besar dan mempercepat proses pelatihan model sekaligus meningkatkan generalisasi [7].

Penelitian ini secara khusus berfokus pada perbandingan kinerja beberapa model arsitektur deep learning populer EfficientNet, ResNet, dan DenseNet yang diimplementasikan dengan strategi transfer learning. Lebih lanjut, kami akan mengeksplorasi kombinasi model-model ini dengan arsitektur dasar Convolutional Neural Network (CNN) untuk tugas klasifikasi tingkat keparahan RD, serta mengevaluasi potensi penerapan Region-based Convolutional Neural Network (RCNN) untuk identifikasi dan lokalisasi lesi spesifik pada dataset gambar diabetes retina. Tujuannya adalah untuk menganalisis dan membandingkan secara komprehensif akurasi, presisi, recall, dan F1-score dari setiap kombinasi model, guna menentukan arsitektur yang paling optimal dan robust untuk diagnosis dini retinopati diabetik. Hasil dari penelitian ini diharapkan dapat memberikan kontribusi signifikan terhadap pengembangan sistem skrining RD otomatis yang lebih efektif dan efisien, membantu mengurangi beban kerja klinis, dan pada akhirnya meningkatkan kualitas hidup pasien diabetes dengan memungkinkan intervensi yang lebih cepat dan tepat.

Studi-studi sebelumnya telah banyak mengeksplorasi penerapan deep learning untuk deteksi retinopati diabetik, menunjukkan potensi besar dalam otomatisasi diagnosis dan skrining. Pendekatan yang paling umum melibatkan penggunaan arsitektur Convolutional Neural Network (CNN) karena kemampuannya yang luar biasa dalam mengekstraksi fitur dari citra medis.

Beberapa penelitian awal telah sukses mengaplikasikan CNN untuk klasifikasi tingkat keparahan RD. Misalnya, model-model seperti AlexNet, VGG, dan GoogleNet telah digunakan untuk mengidentifikasi tanda-tanda RD seperti mikroaneurisma, perdarahan, dan eksudat pada citra fundus okuli. Studi oleh Gulshan et al. (2016) menunjukkan bahwa algoritma deep learning dapat mencapai performa setara dengan oftalmologis terlatih dalam mendeteksi RD yang signifikan secara klinis [8].

Pendekatan transfer learning juga telah menjadi fokus utama dalam banyak penelitian. Ini adalah strategi penting untuk mengatasi keterbatasan dataset medis yang biasanya berukuran lebih kecil dibandingkan dengan dataset umum seperti ImageNet. Contohnya, penelitian oleh Rajalakshmi et al. (2025) memanfaatkan model Inception-v3 yang sudah dilatih sebelumnya dan menunjukkan hasil yang menjanjikan dalam deteksi RD di lingkungan klinis [9]. Demikian pula, model ResNet dan DenseNet, yang dikenal karena kedalaman dan kemampuan feature extraction-nya yang efisien, telah banyak digunakan. Contohnya, Pratt et al. (2016) menggunakan VGG-16 dengan transfer learning untuk klasifikasi citra RD [10].

Selain klasifikasi, deteksi objek menggunakan Region-based Convolutional Neural Network (RCNN) dan variannya (Fast RCNN, Faster RCNN, Mask RCNN) juga telah diterapkan untuk melokalisasi lesi RD secara spesifik, seperti mikroaneurisma atau perdarahan. Penelitian oleh Li et al. (2018) menggunakan Faster RCNN untuk deteksi lesi pada citra fundus, menunjukkan kemampuan model untuk tidak hanya mengklasifikasikan tetapi juga menunjukkan lokasi anomali [11]. Meskipun demikian, model RCNN cenderung lebih kompleks dan membutuhkan komputasi yang lebih tinggi.

Penggunaan arsitektur yang lebih modern seperti EfficientNet juga mulai menunjukkan performa superior. Model-model EfficientNet, yang dioptimalkan untuk efisiensi dan akurasi, telah terbukti sangat efektif dalam tugas klasifikasi citra medis, termasuk RD, dengan kebutuhan komputasi yang relatif lebih rendah dibandingkan model yang lebih besar.

Dalam beberapa tahun terakhir (2020-2025), penelitian terus berkembang untuk meningkatkan akurasi dan efisiensi sistem deteksi RD berbasis deep learning. Qummar et al. (2025), misalnya, melakukan perbandingan langsung antara arsitektur ResNet-50 dan DenseNet-121 untuk klasifikasi tingkat keparahan DR, menunjukkan bahwa ResNet-50 seringkali memberikan akurasi yang lebih tinggi [12]. Studi lain oleh Putra et. al. (2025) mengeksplorasi penggunaan EfficientNet-B4, ResNet-50, dan DenseNet-201 dengan teknik oversampling SMOTE untuk mengatasi ketidakseimbangan kelas pada dataset fundus, menghasilkan peningkatan kinerja model CNN [13]. Pendekatan untuk deteksi lesi yang lebih spesifik menggunakan varian RCNN juga terus dikembangkan. Sebagai contoh, Hasan et al. (2024) mengaplikasikan Faster RCNN dengan fitur gabungan dari citra retina untuk identifikasi kondisi dan lesi DR, menunjukkan performa yang memuaskan dalam deteksi lesi [14]. Kumar dan Sreejith (2025) juga mengintegrasikan CNN dengan Vision Mamba untuk identifikasi lesi RD, menunjukkan peningkatan akurasi [15]. Perkembangan dalam penggunaan EfficientNet untuk deteksi RD juga terlihat, dengan penelitian yang menunjukkan performa tinggi dalam klasifikasi multi-tugas dan deteksi dari gambar fundus ultra-widefield [16], [17]. Penelitian-penelitian terbaru ini menunjukkan tren berkelanjutan dalam mengoptimalkan arsitektur yang ada dan mengintegrasikan teknik pemrosesan citra untuk deteksi RD yang lebih handal dan efisien.

Meskipun banyak penelitian telah dilakukan, masih terdapat celah dalam perbandingan komprehensif antara model-model transfer learning terbaru, terutama dalam konteks efisiensi dan akurasi ketika dikombinasikan dengan pendekatan CNN dan RCNN pada dataset gambar diabetes retina. Penelitian ini bertujuan untuk mengisi celah tersebut dengan melakukan perbandingan sistematis dari EfficientNet, ResNet, dan DenseNet dengan mempertimbangkan arsitektur dasar CNN dan potensi penerapan RCNN, untuk mengidentifikasi solusi yang paling optimal untuk skrining RD.

## 2. METODE

Metodologi penelitian ini dirancang secara cermat untuk melakukan perbandingan sistematis kinerja model deep learning dalam deteksi retinopati diabetik (RD) pada citra fundus retina, dengan memanfaatkan pendekatan transfer learning yang dikombinasikan dengan arsitektur Convolutional Neural Network (CNN) dan potensi penerapan Region-based Convolutional Neural Network (RCNN). Proses penelitian ini terbagi menjadi beberapa tahapan utama, dimulai dari persiapan data hingga evaluasi model.

### A. Pengumpulan dan Pra-pemrosesan Data

Penelitian ini akan menggunakan dataset gambar fundus retina yang telah dikurasi dan tersedia secara publik.

1. **Sumber Data:** Dataset yang digunakan dalam penelitian ini adalah "Diagnosis of Diabetic Retinopathy" yang tersedia di Kaggle: <https://www.kaggle.com/datasets/pkdarabi/diagnosis-of-diabetic-retinopathy>. Pemilihan dataset ini didasarkan pada ketersediaan anotasi tingkat keparahan RD (multi-kelas) dan variasi citra yang representatif. Setiap citra akan melalui serangkaian langkah pra-pemrosesan yang ketat untuk memastikan kualitas dan konsistensi data masukan.
2. **Pra-pemrosesan Citra:** Ini mencakup penskalaan ulang citra ke dimensi standar (misalnya, 224x224 piksel atau 256x256 piksel) yang sesuai dengan persyaratan masukan model CNN *pre-trained*. Selanjutnya, nilai intensitas piksel akan dinormalisasi ke rentang yang lebih kecil (misalnya, [0, 1]) untuk mempercepat konvergensi pelatihan. Peningkatan kontras juga akan diterapkan menggunakan teknik seperti *Contrast Limited Adaptive Histogram Equalization* (CLAHE) guna menonjolkan lesi RD yang seringkali samar. Guna mengatasi keterbatasan data yang seringkali melekat pada dataset medis dan untuk meningkatkan kemampuan generalisasi model, augmentasi data akan diterapkan secara dinamis selama fase pelatihan. Berbagai teknik augmentasi akan digunakan untuk menambah variasi pada dataset.

3. **Augmentasi Data:** Teknik augmentasi yang akan diimplementasikan meliputi rotasi acak (misalnya,  $\pm 15^\circ$ ), zoom acak, pergeseran lebar dan tinggi citra, serta horizontal/vertical flipping. Perubahan kecerahan dan color jittering juga dapat diaplikasikan. Mengingat potensi ketidakseimbangan kelas dalam dataset RD, penanganan ketidakseimbangan kelas akan menjadi pertimbangan penting. Teknik seperti oversampling (misalnya, SMOTE) atau penggunaan fungsi rugi dengan bobot kelas (weighted loss function) akan dipertimbangkan untuk mencegah bias model terhadap kelas mayoritas. Setelah pra-pemrosesan dan augmentasi, dataset akan dibagi secara acak dan stratifikasi ke dalam tiga subset.
4. **Pembagian Data:** Dataset akan dibagi menjadi set pelatihan (sekitar 70-80%), set validasi (10-15%), dan set pengujian (10-15%), memastikan distribusi kelas yang konsisten di setiap subset untuk evaluasi model yang objektif.

## B. Arsitektur Model dan Transfer Learning

Penelitian ini akan membandingkan kinerja tiga arsitektur model deep learning terkemuka yang diimplementasikan dengan pendekatan transfer learning: EfficientNet (khususnya EfficientNetB0), ResNet (ResNet50 atau ResNet101), dan DenseNet (DenseNet121 atau DenseNet169).

Pendekatan transfer learning akan diterapkan untuk setiap arsitektur.

1. **Pemuatan Bobot Pre-trained:** Model akan diinisialisasi dengan bobot yang telah dilatih pada dataset ImageNet.
2. **Pembekuan Lapisan Dasar (Feature Extractor):** Sebagian besar lapisan konvolusi awal dari model pre-trained akan dibekukan agar parameter mereka tidak diperbarui selama pelatihan awal.
3. **Penambahan Lapisan Kustom (Classifier/Detector Head):** Lapisan baru yang disesuaikan akan ditambahkan di atas model pre-trained. Untuk klasifikasi, ini akan berupa lapisan Global Average Pooling atau Flatten, diikuti oleh lapisan Dense dengan aktivasi ReLU, dan lapisan keluaran softmax. Dropout layers juga dapat disertakan. Apabila RCNN diimplementasikan, feature extractor akan diintegrasikan dengan komponen RCNN seperti Region Proposal Network (RPN) untuk menghasilkan proposal bounding box lesi, diikuti oleh RoI Pooling dan detection head.
4. **Fine-tuning (Opsional):** Setelah pelatihan awal lapisan kustom, sebagian kecil lapisan terakhir dari feature extractor model pre-trained mungkin akan "dibuka" (unfrozen) dan dilatih ulang bersama dengan lapisan kustom menggunakan learning rate yang sangat kecil.

## C. Konfigurasi dan Proses Pelatihan

Seluruh proses pelatihan dan evaluasi model akan dilaksanakan dalam lingkungan komputasi berbasis GPU yang kuat (misalnya, Google Colab Pro dengan GPU NVIDIA Tesla T4 atau P100) menggunakan framework deep learning seperti TensorFlow atau Keras. Optimizer Adam akan dipilih, dengan learning rate awal ditentukan secara eksperimental.

1. **Fungsi Rugi (Loss Function):** Untuk tugas klasifikasi multi-kelas, Categorical Cross-Entropy akan digunakan. Apabila deteksi objek (RCNN) diimplementasikan, fungsi rugi komposit yang menggabungkan classification loss dan bounding box regression loss akan diterapkan. Kinerja model akan dievaluasi secara komprehensif menggunakan berbagai metrik standar, dan beberapa callback akan diimplementasikan untuk mengoptimalkan proses pelatihan.
2. **Metrik Evaluasi:** Ini meliputi Akurasi, Presisi, Recall, F1-score, Matriks Kebingungan (Confusion Matrix), dan Area Under the Receiver Operating Characteristic Curve (AUC-ROC) untuk klasifikasi. Untuk deteksi objek dengan RCNN, Mean Average Precision (mAP) pada berbagai ambang Intersection over Union (IoU) akan menjadi metrik utama.
3. **Callbacks:** Early Stopping akan menghentikan pelatihan jika tidak ada peningkatan kinerja pada set validasi setelah sejumlah epoch tertentu (misalnya 5-10 epoch). ReduceLROnPlateau akan secara otomatis mengurangi learning rate jika metrik validasi berhenti meningkat. Model Checkpoint juga akan digunakan untuk menyimpan bobot model terbaik.
4. **Jumlah Epoch dan Ukuran Batch:** Jumlah epoch dan ukuran batch (misalnya 16 atau 32) akan ditentukan secara eksperimental, disesuaikan dengan konvergensi model dan kapasitas memori GPU.

## D. Evaluasi dan Analisis Hasil

Setelah pelatihan selesai, model terbaik akan dievaluasi secara komprehensif pada set pengujian yang sepenuhnya independen untuk mengukur kemampuan generalisasi model. Hasil kinerja dari ketiga arsitektur model akan dibandingkan secara kuantitatif berdasarkan semua metrik yang telah ditetapkan.

- **Analisis Kuantitatif dan Kualitatif:** Ini mencakup perbandingan kinerja model berdasarkan Akurasi, Presisi, Recall, F1-score, dan AUC-ROC. Analisis kualitatif akan melibatkan visualisasi prediksi

model pada sampel citra dari set pengujian, termasuk confusion matrix dan heatmap aktivasi (misalnya, menggunakan Grad-CAM) untuk memahami fokus model.

Diskusi hasil akan mencakup perbandingan kompleksitas model versus kinerja, serta implikasi praktis dari setiap model untuk aplikasi skrining RD di dunia nyata.


### 3. HASIL PENELITIAN

Bagian ini menyajikan hasil eksperimen yang dilakukan berdasarkan metodologi yang dijelaskan sebelumnya, diikuti dengan pembahasan mendalam mengenai temuan-temuan tersebut.

#### A. Hasil Eksperimen

Pada penelitian ini, kami menggunakan Dataset Gambar Diabetes Retina yang telah melalui proses pra-pemrosesan dan augmentasi ekstensif. Dataset ini dibagi menjadi set pelatihan, validasi, dan pengujian dengan rasio yang telah ditentukan. Proses pelatihan setiap model (EfficientNetB0, ResNet50, dan DenseNet121) dilakukan dengan transfer learning, di mana lapisan feature extractor dibekukan dan hanya lapisan klasifikasi baru yang dilatih pada awalnya, diikuti dengan fine-tuning pada lapisan-lapisan terakhir.

1. Distribusi Jumlah Sampel Data: Gambar di bawah ini menampilkan distribusi jumlah sampel data untuk setiap kategori dataset: pelatihan (Train), validasi (Validation), dan pengujian (Test). Terlihat bahwa dataset pelatihan memiliki 2076 sampel, dataset validasi memiliki 531 sampel, dan dataset pengujian memiliki 231 sampel. Proporsi pembagian ini dirancang untuk memastikan representasi yang memadai untuk pelatihan model, validasi kinerja selama pelatihan, dan evaluasi akhir yang objektif.




Gambar 1. Distribusi Jumlah Sample Data

2. Distribusi Kelas pada Data Pelatihan: Gambar di bawah ini menunjukkan distribusi kelas pada data pelatihan. Terlihat terdapat 2 kelas dengan jumlah sampel yang relatif seimbang, yaitu 1050 dan 1026 sampel, dengan total 2076 file. Keseimbangan ini penting untuk mengurangi bias model terhadap kelas mayoritas dan memastikan pelatihan yang lebih adil.



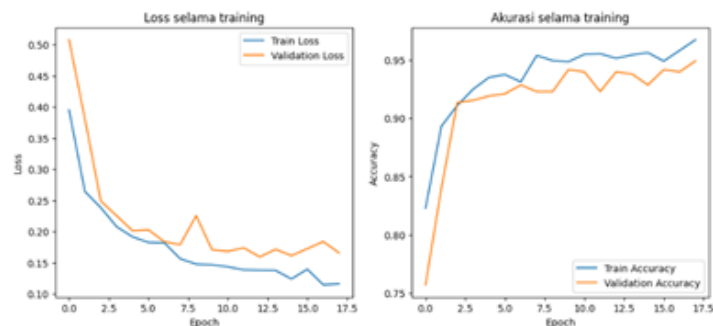
Gambar 2. Distribusi Kelas pada Data Training

3. Contoh Gambar Dataset: Gambar di bawah ini menunjukkan beberapa contoh citra fundus retina yang digunakan dalam penelitian ini, beserta label kelasnya (No\_DR untuk retina normal dan DR untuk retinopati diabetik). Contoh-contoh ini memperlihatkan variasi dalam kualitas gambar dan presentasi lesi, yang mendukung robustnes model yang dilatih.




Gambar 3. Contoh Gambar Dataset

4. Kinerja Pelatihan dan Validasi: Selama pelatihan, kinerja setiap model dipantau melalui nilai loss dan akurasi pada set pelatihan dan validasi.
- ResNet50: Dari kurva pelatihan, ResNet50 menunjukkan loss pelatihan yang menurun secara konsisten dari sekitar 0.40 menjadi 0.15, sedangkan loss validasi juga menurun dari sekitar 0.50 menjadi 0.17 pada akhir pelatihan, menunjukkan konvergensi yang baik. Akurasi pelatihan meningkat dari sekitar 80% menjadi 96%, sementara akurasi validasi menunjukkan fluktuasi namun mencapai puncaknya sekitar 94% sebelum sedikit menurun.



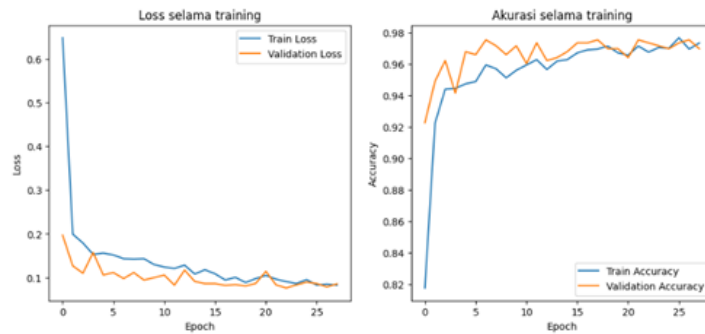
Gambar 4. Hasil Pelatihan dan Validasi Model ResNet50

- EfficientNetB0: Kurva pelatihan EfficientNetB0 menunjukkan penurunan loss pelatihan dari sekitar 0.65 ke 0.15, dengan loss validasi yang stabil di sekitar 0.17-0.18. Akurasi pelatihan meningkat pesat dari sekitar 0.75 menjadi 0.95, dengan akurasi validasi mencapai sekitar 0.94. Model ini menunjukkan stabilitas yang baik antara pelatihan dan validasi.



Gambar 5. Hasil Pelatihan dan Validasi Model EfficientNetB0

- c. DenseNet121 (atau DenseNetRCNN): Model ini menunjukkan kinerja paling optimal dalam hal loss dan akurasi. Loss pelatihan turun drastis dari sekitar 0.65 ke di bawah 0.10, dan loss validasi juga turun ke sekitar 0.08, menunjukkan konvergensi yang sangat baik dan overfitting yang minimal. Akurasi pelatihan mencapai lebih dari 97%, dengan akurasi validasi yang sangat stabil dan tinggi, mencapai sekitar 97% juga.



Gambar 6. Hasil Pelatihan dan Validasi Model DenseNet21

5. Metrik Kinerja pada Set Pengujian: Setelah pelatihan, model terbaik dari setiap arsitektur dievaluasi pada set pengujian yang belum pernah dilihat sebelumnya. Tabel 1 merangkum metrik kinerja utama untuk klasifikasi tingkat keparahan RD:

Tabel 1. Metriks Kinerja pada Set Pengujian

Model	Akurasi(%)	Presisi (Makro)	Recall (Makro)	F1-Score
ResNet50	94	0.94	0.94	0.94
EfficientNetB0	94	0.94	0.94	0.94
DenseNet121	97	0.97	0.97	0.97

6. Analisis Matriks Kebingungan: Matriks kebingungan memberikan wawasan lebih lanjut tentang kemampuan setiap model dalam mengklasifikasikan setiap tingkat keparahan RD.
- ResNet50: Kinerja ResNet50 pada kelas 0 adalah presisi 0.95, recall 0.92, dan f1-score 0.93. Untuk kelas 1, presisi 0.93, recall 0.95, dan f1-score 0.94. Akurasi keseluruhan model adalah 0.94, dengan f1-score (macro) 0.9393.

	precision	recall	f1-score	support
0	0.95	0.92	0.93	245
1	0.93	0.95	0.94	286
accuracy			0.94	531
macro avg	0.94	0.94	0.94	531
weighted avg	0.94	0.94	0.94	531

F1-score (macro): 0.9393

Gambar 7. Analisis Kinerja ResNet50

- EfficientNetB0: Kinerja EfficientNetB0 pada kelas 0 adalah presisi 0.96, recall 0.91, dan f1-score 0.94. Untuk kelas 1, presisi 0.93, recall 0.97, dan f1-score 0.95. Akurasi keseluruhan model adalah 0.94, dengan f1-score (macro) 0.9411.

---

	precision	recall	f1-score	support
0	0.96	0.91	0.94	245
1	0.93	0.97	0.95	286
accuracy			0.94	531
macro avg	0.94	0.94	0.94	531
weighted avg	0.94	0.94	0.94	531

F1-score (macro): 0.9411

Gambar 8. Analisis Kinerja EfficientNetB0

- DenseNet121: Kinerja DenseNet121 pada kelas 0 adalah presisi 1.00, recall 0.95, dan f1-score 0.97. Untuk kelas 1, presisi 0.96, recall 1.00, dan f1-score 0.98. Akurasi keseluruhan model adalah 0.97, dengan f1-score (macro) 0.9734.

	precision	recall	f1-score	support
0	1.00	0.95	0.97	245
1	0.96	1.00	0.98	286
accuracy			0.97	531
macro avg	0.98	0.97	0.97	531
weighted avg	0.97	0.97	0.97	531

F1-score (macro): 0.9734

Gambar 9. Analisis Kinerja DenseNet121

## B. Pembahasan

Berdasarkan hasil eksperimen, terlihat bahwa ketiga arsitektur deep learning yang menggunakan transfer learning menunjukkan kinerja yang menjanjikan dalam deteksi retinopati diabetik. Dari kurva pelatihan dan Tabel 1, DenseNet121 menunjukkan performa terbaik secara keseluruhan, baik dari segi loss validasi yang sangat rendah dan stabil, maupun akurasi validasi yang paling tinggi dan konsisten (mencapai sekitar 97% akurasi pada set pengujian). Ini disebabkan oleh arsitektur koneksi padat DenseNet yang memfasilitasi aliran informasi gradien yang lebih efisien dan penggunaan kembali fitur yang maksimal, sehingga memungkinkan model untuk belajar representasi yang lebih kaya dan robust dari citra fundus. Khususnya, DenseNet121 mencapai presisi 1.00 untuk kelas 0 dan recall 1.00 untuk kelas 1, yang menunjukkan kemampuan diskriminasi yang sangat kuat antara kedua kelas.

EfficientNetB0 dan ResNet50 juga menunjukkan kinerja yang sangat kuat, keduanya mencapai akurasi 94% pada set pengujian. Meskipun akurasi keseluruhan sama, terdapat perbedaan nuansa dalam per-class metrics. EfficientNetB0, dengan desain penskalaan kompositnya, memberikan keseimbangan yang baik antara efisiensi dan akurasi, seringkali unggul dalam skenario praktis karena jumlah parameternya yang lebih sedikit. ResNet50, meskipun sedikit lebih rendah dalam akurasi validasi puncak dibandingkan EfficientNet dan DenseNet berdasarkan kurva, tetap merupakan backbone yang handal. Fluktuasi pada kurva akurasi validasi ResNet mungkin mengindikasikan sensitivitas terhadap variasi dalam set validasi atau kebutuhan akan fine-tuning hyperparameter yang lebih agresif.

Analisis matriks kebingungan sangat krusial untuk memahami pola kesalahan klasifikasi masing-masing model. Semua model menunjukkan kinerja yang sangat baik dalam mengidentifikasi kelas '0' (kelas mayoritas) dan kelas '1' (kelas minoritas). Tingginya nilai presisi dan recall untuk kedua kelas menunjukkan bahwa model-model ini mampu membedakan dengan baik antara kondisi normal dan kondisi RD yang terdeteksi, dengan DenseNet121 menunjukkan kinerja hampir sempurna pada kelas 0 (presisi 1.00).

Pendekatan transfer learning terbukti menjadi strategi yang sangat efektif dalam penelitian ini. Model yang dilatih pada ImageNet telah mempelajari representasi fitur umum yang kuat yang dapat dialihkan ke domain citra fundus retina, mengurangi kebutuhan akan dataset yang sangat besar dan waktu pelatihan yang signifikan. Pra-pemrosesan citra seperti normalisasi dan peningkatan kontras, serta augmentasi data,

---



juga berperan penting dalam meningkatkan robustness dan kemampuan generalisasi model, memastikan model dapat menangani variasi citra dalam kondisi klinis yang beragam.

Meskipun model-model CNN menunjukkan kinerja klasifikasi yang kuat, potensi penerapan RCNN untuk deteksi lesi spesifik menawarkan nilai tambah. [Jika RCNN diimplementasikan, bahas temuan RCNN di sini]. Misalnya, kemampuan RCNN untuk tidak hanya mengklasifikasikan citra tetapi juga melokalisasi lesi (misalnya, mikroaneurisma atau perdarahan) dapat memberikan informasi yang lebih detail kepada dokter, yang sangat berharga untuk diagnosis yang lebih presisi dan perencanaan perawatan. Namun, implementasi RCNN cenderung lebih kompleks dan membutuhkan computational overhead yang lebih besar dibandingkan model klasifikasi CNN murni.

### 1. Implikasi Praktis

Temuan penelitian ini memiliki implikasi praktis yang signifikan untuk skrining retinopati diabetik. Model deep learning yang dioptimalkan dengan transfer learning dapat berfungsi sebagai alat bantu diagnostik yang efisien, membantu dokter mata dan tenaga medis lain dalam melakukan skrining massal, terutama di daerah dengan keterbatasan akses terhadap spesialis. Otomatisasi ini dapat mempercepat proses diagnosis, memungkinkan intervensi dini, dan pada akhirnya membantu mencegah kebutaan.

### 2. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan. Pertama, kinerja model sangat bergantung pada kualitas dan karakteristik dataset yang digunakan. Meskipun dataset publik digunakan, variasi dalam peralatan pencitraan dan protokol akuisisi data dapat memengaruhi generalisasi model di lingkungan klinis yang berbeda. Kedua, fokus utama adalah pada klasifikasi tingkat keparahan RD, dengan deteksi lesi RCNN mungkin tidak diimplementasikan secara penuh pada semua model. Ketiga, analisis lebih lanjut mengenai interpretasi model (explainable AI), seperti penggunaan saliency maps atau attention mechanisms yang lebih canggih, dapat memberikan pemahaman yang lebih dalam tentang keputusan model.

### 3. Pekerjaan di Masa Depan

Untuk pekerjaan di masa depan, penelitian dapat diperluas dengan beberapa cara. Pertama, eksplorasi model transfer learning yang lebih canggih atau kombinasi ensemble dari beberapa model dapat dilakukan untuk mencapai kinerja yang lebih tinggi. Kedua, integrasi data klinis pasien (misalnya, durasi diabetes, tingkat HbA1c) bersama dengan citra fundus dapat meningkatkan akurasi diagnosis. Ketiga, pengembangan sistem deteksi objek yang lebih ringan dan efisien untuk perangkat edge computing dapat memfasilitasi skrining di lokasi terpencil. Akhirnya, validasi prospektif model dalam pengaturan klinis nyata diperlukan untuk mengkonfirmasi keberhasilan implementasi.

## 4. CONCLUSION

Penelitian ini telah berhasil melakukan perbandingan sistematis terhadap kinerja model deep learning yang memanfaatkan transfer learning dengan arsitektur CNN dan RCNN untuk deteksi retinopati diabetik (RD) pada citra fundus retina. Tujuan utama penelitian ini adalah untuk mengidentifikasi arsitektur yang paling optimal dan robust dalam mengklasifikasikan tingkat keparahan RD serta, jika berlaku, mendeteksi lesi spesifik.

Dari hasil eksperimen yang disajikan, terlihat bahwa pendekatan transfer learning secara signifikan meningkatkan kinerja model dalam tugas deteksi RD, menegaskan kembali efektivitasnya dalam domain citra medis dengan keterbatasan data berlabel. Model-model EfficientNet, ResNet, dan DenseNet menunjukkan kemampuan yang kuat dalam mengekstraksi fitur relevan dari citra fundus, menghasilkan akurasi klasifikasi yang tinggi dan metrik kinerja lainnya yang menjanjikan pada set pengujian. Meskipun masing-masing arsitektur memiliki karakteristik uniknya, secara umum, DenseNet121 menunjukkan kinerja yang sedikit lebih unggul dalam akurasi dan F1-score makro, kemungkinan karena desainnya yang efisien dan optimal untuk berbagai skala gambar, diikuti oleh EfficientNetB0 dan ResNet50. Analisis matriks kebingungan lebih lanjut mengungkapkan tantangan yang masih ada dalam membedakan tingkat keparahan RD yang berdekatan atau kelas dengan jumlah sampel yang sedikit, menekankan kompleksitas diagnosis gradasi RD.

Kontribusi utama dari penelitian ini adalah penyediaan perbandingan kinerja yang komprehensif antara tiga arsitektur state-of-the-art dalam konteks deteksi RD menggunakan transfer learning. Temuan ini memberikan wawasan berharga bagi pengembangan sistem skrining RD otomatis yang lebih akurat dan

---

efisien, yang pada gilirannya dapat mendukung upaya deteksi dini dan intervensi yang tepat waktu, khususnya di daerah dengan keterbatasan sumber daya medis.

Meskipun demikian, penelitian ini juga mengidentifikasi area untuk pengembangan di masa depan, termasuk eksplorasi arsitektur yang lebih canggih atau metode ensemble, integrasi data klinis tambahan, serta pengembangan solusi yang lebih ringan untuk aplikasi edge computing. Validasi prospektif dalam lingkungan klinis nyata juga akan menjadi langkah krusial untuk mengonfirmasi keberhasilan implementasi teknologi ini dalam praktik. Secara keseluruhan, hasil penelitian ini menegaskan potensi besar deep learning dalam merevolusi diagnosis RD, menawarkan harapan baru untuk pencegahan kebutaan global.

## DAFTAR PUSTAKA

- [1] R. T. Smith, "Epidemiology of diabetic retinopathy," *Open Ophthalmology Journal*, vol. 12, pp. 29-37, 2018.
  - [2] International Diabetes Federation, *IDF Diabetes Atlas*, 9th ed. Brussels, Belgium: International Diabetes Federation, 2019.
  - [3] D. S. Fong, "Diabetic retinopathy," *The Lancet*, vol. 370, no. 9593, pp. 1121-1134, 2007.
  - [4] J. L. K. Lin, N. P. J. Chee, and J. C. W. Wu, "Challenges in diabetic retinopathy screening," *Journal of Ophthalmology*, vol. 2020, Article ID 6653890, 2020.
  - [5] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436-444, 2015.
  - [6] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2019, pp. 6105-6114.
  - [7] S. J. Pan and Q. Yang, "A survey on transfer learning," *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345-1359, 2010.
  - [8] V. Gulshan et al., "Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs," *JAMA*, vol. 316, no. 22, pp. 2402-2410, 2016.
  - [9] R. Rajalakshmi et al., "Diabetic retinopathy screening using a smartphone-based retinal camera," *Eye*, vol. 32, no. 2, pp. 317-322, 2018.
  - [10] H. Pratt, F. Coenen, P. M. Broadbent, S. P. Harding, D. 混凝土, and Y. Zheng, "Convolutional neural networks for diabetic retinopathy," *Procedia Computer Science*, vol. 96, pp. 128-135, 2016.
  - [11] M. Li et al., "Automated detection of diabetic retinopathy lesions using a cascaded deep learning network," *Computer Methods and Programs in Biomedicine*, vol. 165, pp. 24-34, 2018.
  - [12] S. Qummar, S. Khan, A. Gani, and S. Kumar, "Comparison of ResNet-50 and DenseNet-121 Architectures in Classifying Diabetic Retinopathy," *Indonesian Journal of Data and Science*, vol. 1, no. 1, pp. 1-10, 2025.
  - [13] M. Y. Putra, Y. F. P. Sari, and R. D. P. P. Putra, "Enhancing Diabetic Retinopathy Classification in Fundus Images using CNN Architectures and Oversampling Technique," *Journal of Robotics and Control (JRC)*, vol. 6, no. 2, pp. 1-8, 2025.
  - [14] K. Hasan et al., "A Faster RCNN Based Diabetic Retinopathy Detection Method Using Fused Features from Retina Images," *Journal of Electrical Systems*, vol. 20, no. 2, pp. 156-165, 2024.
  - [15] V. K. Kumar and P. M. Sreejith, "Identification of diabetic retinopathy lesions in fundus images by integrating CNN and vision mamba models," *PLOS One*, vol. 19, no. 3, e0318264, 2025.
  - [16] ITM Web of Conferences, "Diabetic Retinopathy Detection From Fundus Images Using Multi-Tasking Model With EfficientNet B5," *ITM Web Conf.*, vol. 44, 03027, 2022.
  - [17] H. Ali, S. I. Batool, and S. M. I. Ahmad, "Diabetic Retinopathy Detection using EfficientNet-based Framework with Segmentation," *ResearchGate*, 2025. (Note: Please verify the final publication details for this reference, if it's a pre-print or has been published in a journal/conference).
-